


Probabilidad de impago

1. El Inicio: Objetivo del Estudio

- **¿Qué buscamos?** No solo queremos "predecir el futuro", sino crear una herramienta que diferencie automáticamente a un **Buen Cliente (0)** de un **Mal Cliente (1)**. El objetivo es reducir la tasa de impago y agilizar la aprobación de créditos.
- **El Desafío:** Nuestra base de datos tiene muchos más clientes buenos que malos. Esto es un "sesgo" natural que obliga al modelo a ser muy inteligente para no ignorar a los pocos clientes morosos.




2. El Proceso: Preparando los Datos

- Antes de entrenar modelos, "limpiamos la casa":
- **Tratamiento de nulos:** Completamos la información faltante en ingresos y cuotas usando la **mediana**. Esto evita que datos extremos o vacíos confundan al modelo.
- **Ingeniería de variables:** Convertimos categorías (como género o nivel de estudios) en formatos numéricos para que los algoritmos puedan procesarlos.
- **División de Control:** Separamos los datos en **70% para entrenamiento** y **30% para prueba**. Esto nos permite evaluar los modelos con datos que nunca han visto.

3. Radiografía del Riesgo: ¿Qué nos dicen las variables?

- Utilizamos un análisis de importancia para ver qué factores "pesan" más en la decisión.
- **Hallazgo principal:** Las variables relacionadas con el **ingreso propio** y la **cuota de préstamos actuales** son los indicadores más fuertes.
- **Valor para el negocio:** Esto valida que nuestro modelo está mirando los factores financieros correctos y no solo correlaciones al azar.

Top 20 Variables con Mayor Impacto en el Modelo de Riesgo



4. El Campo de Entrenamiento: Los 4 Modelos.

- Probamos cuatro "cerebros" diferentes:
- **Regresión Logística:** El modelo clásico, fácil de explicar pero a veces demasiado simple.
- **Random Forest:** Un bosque de árboles de decisión que busca patrones grupales.
- **XGBoost:** Un modelo de alta velocidad diseñado para ganar competencias de precisión.
- **Gradient Boosting:** Un modelo que aprende de sus propios errores de forma iterativa.

5. Resultados y Comparativa Final

- Usamos tres métricas de oro en la banca:
- **AUC:** Capacidad general de distinguir entre clases.
- **Gini:** Calidad de la distribución del score (entre más alto, mejor).
- **K-S (Kolmogorov-Smirnov):** Qué tan bien separamos a los "Buenos" de los "Malos".


Resultados y Comparativa Final

Modelo	AUC	Gini	K-S (Separación)
Regresión Logística	0.6893	0.3786	0.2825
Random Forest	0.6979	0.3959	0.2836
XGBoost	0.6945	0.3889	0.2866
Gradient Boosting	0.7236	0.4472	0.3454


6. Resultados de Modelado: Regresión Logística

- **Regresión Logística (Línea Base):**
 - **Métricas:** AUC: 0.6893 | Gini: 0.3786 | K-S: 0.2825.
 - **Análisis:** Es el modelo más estable y fácil de explicar. Sin embargo, mostró una tendencia conservadora, priorizando la identificación de clientes buenos pero con baja sensibilidad ante los perfiles de riesgo.

Curva ROC - Regresión Logística




Matriz de Confusión - Regresión Logística




7. Resultados de Modelado: Random Forest

- **Random Forest (Ensamble de Árboles):**
- **Métricas:** AUC: 0.6979 | Gini: 0.3959 | K-S: 0.2836.
- **Análisis:** Supera ligeramente a la logística al capturar relaciones no lineales entre las variables. Es robusto frente a datos atípicos, aunque mantiene dificultades para aislar la clase minoritaria de impago.

Curva ROC - Bosques Aleatorios




Matriz de Confusión - Bosques Aleatorios




8. Resultados de Modelado: XGBoost

- **XGBoost (Extreme Gradient Boosting):**
 - **Métricas:** AUC: 0.6945 | Gini: 0.3889 | K-S: 0.2866.
 - **Análisis:** Destaca por su eficiencia técnica y velocidad. Presentó una mejora en la detección de clientes con riesgo (Recall clase 1: 0.19) comparado con los modelos anteriores, demostrando ser más agresivo en la búsqueda de patrones de mora.

Curva ROC - XGBoost





Matriz de Confusión - XGBoost



8. Resultados de Modelado: Gradient Boosting

- **Gradient Boosting (Potenciación por Gradiente):**
- **Métricas:** AUC: 0.7236 | Gini: 0.4472 | K-S: 0.3454.
- **Análisis:** Presentó el equilibrio más alto entre precisión y sensibilidad. Su capacidad para corregir errores de forma secuencial le permitió alcanzar la mayor separación de grupos (K-S) del estudio.



9. La Matriz de Confusión

- Esta diapositiva nos permite ver dónde están los éxitos y los desafíos del modelo ganador:
- **Verdaderos Positivos (Aciertos en Riesgo):** Clientes que el modelo identificó correctamente como morosos.
- **Verdaderos Negativos (Aciertos en Buenos Clientes):** Clientes sanos que el modelo aprobó sin problemas (nuestro punto más fuerte).
- **Falsos Positivos:** Clientes buenos que el modelo marcó como riesgo.
- **Falsos Negativos:** El reto principal; clientes morosos que el modelo no detectó.
- **Conclusión técnica:** El modelo es excelente protegiendo la cartera de clientes buenos, y el Gradient Boosting es el que mejor logra capturar a los clientes difíciles (Clase 1).

10. Resumen.

- El estudio constituye un ciclo de vida completo de Ciencia de Datos aplicado a finanzas:
- **Ingesta y Calidad:** Procesamiento de 41 variables y tratamiento de valores nulos en ingresos y cuotas mediante la mediana.
- **Validación de Hipótesis:** Confirmación de que el nivel de ingresos y el historial de cuotas son los predictores más potentes en los 4 modelos.
- **Arquitectura de Prueba:** Implementación de una división 70/30 para asegurar que las métricas obtenidas sean representativas de la realidad y no producto del azar.
- **Auditoría Integral:** Evaluación bajo tres dimensiones (AUC para capacidad general, Gini para calidad de scoring y K-S para capacidad de separación).

11. Conclusiones Técnicas:

- **Efectividad Demostrada:** Los 4 métodos superan el umbral mínimo industrial de K-S (> 0.25), lo que confirma que el modelo de datos es capaz de predecir el comportamiento de pago de forma fiable.
- **Naturaleza del Riesgo:** La superioridad de los modelos de árboles y boosting sugiere que el riesgo crediticio en esta cartera no es lineal, sino que depende de combinaciones complejas de variables.
- **Capacidad de Separación:** El rango de K-S obtenido (0.28 a 0.34) permite crear estrategias de segmentación sólidas para el área de cobranza y admisión.

12. Recomendaciones para el Negocio.

- **Escalabilidad:** El trabajo realizado deja una base sólida para que el negocio elija el método según su necesidad: la **Logística** por su transparencia legal o el **Gradient Boosting** por su precisión técnica.
- **Focalización de Esfuerzos:** Independientemente del modelo, el sistema de scoring debe priorizar la verificación de la capacidad de pago propia, ya que fue el factor determinante en el éxito de las 4 predicciones.
- **Monitoreo y reentrenamiento continuos:** monitoree regularmente el desempeño del modelo con nuevos datos y reentreno periódicamente para asegurar su continua precisión y relevancia a medida que cambian las condiciones del mercado.